Скаут

Платформа обратного найма ИТ-специалистов с верифицированным профилем ФСП

Спецтрек ФСП · ЛЦТ 2026 · Техническая документация

Техническая документация

Назначение и границы

Скаут связывает работодателей с анонимными профилями ИТ-специалистов. Доверенные сигналы отделены от заявленных: категория возникает из теста, достижения ФСП влияют на подбор при проверке и согласии кандидата, внешние резюме оцениваются без приписывания им этих сигналов. Документ описывает архитектуру, API, тест, подбор, развёртывание и валидацию.

Архитектура

React + TypeScript + Vite → `/api/v1` NestJS → PostgreSQL через Prisma. Keycloak выдаёт OIDC-токены по Authorization Code + PKCE; API проверяет JWT и JWKS. Redis/BullMQ обслуживает фоновую очередь. Отдельный worker проверяет код через Piston, назначает регулярные задания и обрабатывает удаление аккаунтов. PDF-резюме обрабатываются Python-инструментами в runtime-контейнере backend. Frontend раздаёт nginx; на публичном стенде Caddy завершает TLS.

API и данные

Источник контракта: `contracts/openapi.yaml`; матрица операций: `docs/api-matrix.md`. Входные тела проверяются Zod-схемами; ошибки возвращаются в формате RFC 9457. Снимки моделей frontend/backend проверяет `npm run check:contract` (232 файла моделей).

Основные области: профиль кандидата/компании, согласия, потребности, поиски, тесты и ответы, приглашения, вакансии/отклики, регулярные задания, достижения ФСП и внешняя оценка ранжирования. Схема хранения и SQL-миграции находятся в `backend/prisma`. Не заменяйте миграции командой `db push` при сдаче.

`POST /api/v1/eval/rank` принимает вакансии и резюме с идентификаторами, возвращает ранжирование и факторы. Нужна роль employer/admin. JSON Resume исключает поля имени, контактов и адреса из текстового подбора. CSV-выдача экранирует кавычки и нейтрализует формулы ячеек.

Тестирование кандидата

В исходниках реализованы выбор семейств CAT, 2PL/EAP, ограничения экспозиции, контроль компетенций, практика с кодом, серверная проверка ответов, последовательные состояния сессии и защита от повторных ответов. Ключи объективных заданий остаются на сервере. Необработанный код или свободный ответ не может автоматически стать подтверждённым верным ответом. Отсутствие или провал обязательной практики не заменяется высоким CAT-результатом.

Банк `expert-bank-20261010-v3`: 160 параметрических семейств, 38–54 на специализацию. Параметры a и b — экспертные приоритеты; калибровка по реальным ответам предусмотрена после пилота. Проверка песочницы требует реального Piston с установленными версиями рантаймов. Без Piston практика отключается, и категория подтверждается адаптивным блоком.

Подбор и объяснения

Публикация требует подтверждённую категорию и согласие. Учитываются скрытые компании, доступность, формат, город/релокация и обязательные навыки. Один грейд ниже запроса допускается со штрафом 8 баллов и пометкой в chips. Специализация остаётся строгой. Совпадение с выбранным грейдом имеет приоритет над соседними выбранными категориями. Итог ограничен диапазоном 0–100, отображаемые вклады суммируются в итоговую оценку.

Внутренний подбор использует покрытие навыков, Jaccard, отрасль, условия, перцентиль, подтверждённые навыки, регулярные задания и достижения ФСП. Внешний подбор использует покрытие словаря и BM25. Эти два режима различаются доступными доказательствами и не должны сравниваться как одинаковые модели.

Приватность и контроль доступа

Контакты раскрываются в контексте конкретной компании после согласия. Внешнее резюме не доказывает личность, тест или достижение. Подтверждение ФСП принимает подписанные webhook-данные с HMAC по исходным байтам. Удаление личности учитывает issuer и subject; worker обращается к Keycloak с отдельными служебными credentials. Шифрование контактов на уровне полей БД по пункту 4.5 плана ещё не внедрено.

Развёртывание

Локально: `docs/local-deployment.md`; публично: `docs/public-deployment.md`. Образы backend разделяют build/migrate/runtime. API и worker работают без root, с read-only файловой системой и временным `/tmp`. Compose ожидает PostgreSQL, Redis и завершение миграций. Готовность API проверяется `/api/v1/ready`; этот endpoint не заменяет отдельную проверку OIDC и Piston.

Валидация

Валидация воспроизводится командой `npm run eval` (backend), подробности в `docs/validation.md`. На 2000 синтетических кандидатах с независимым генератором ответов (3PL со сдвинутыми параметрами): точный грейд 59,0% (в продуктовом сценарии 61,8%), взвешенная к 0,82, ложные отказы 22,9%, r($\hat{\theta}$, θ) 0,87, test-retest к 0,73. При сливе ключей всех экземпляров $\hat{\theta}$ завышается на +0,64 против +2,74 у фиксированного теста. Подбор на отложенной выборке: nDCG@10 0,514 против 0,309 у BM25, P@10 0,609 против 0,361.

Какие модели, как и зачем

Сейчас LLM не участвует в подтверждении навыков и не подключена к генерации боевого банка. Планируется GigaChat или YandexGPT для черновиков: постановка, навык, варианты ответа, объяснение и эталон → экспертная проверка → изолированная проверка эталона → пилот → калибровка сложности и времени. До этой проверки черновики не должны попадать в подтверждающий тест. Версия модели, prompt, параметры, рецензент и дата должны сохраняться в происхождении задания; реальные персональные данные в prompt не передаются. Сгенерированных и прошедших экспертную проверку заданий в этой итерации нет.

Локальный запуск всего стека

Быстрый путь для проверки: `cd infra && cp .env.example .env && docker compose up --build`, затем http://localhost:8081. Сервис `seed` наполняет базу демо-данными, сервис `web` собирает фронтенд в режиме реального API и проксирует /api на api:8000. Демо-учётки (пароль `demo12345`) импортируются вместе с realm, их список в корневом README.md. Клиент `scout-e2e` с password grant нужен только для локальных сквозных проверок API.

В infra/compose.yaml добавлены migrate, api и worker. Dockerfile backend содержит отдельные стадии сборки, миграций и запуска. В runtime входят Python и pypdf для резюме; приложение работает пользователем node. API/worker имеют read-only файловую систему, временный /tmp, лимиты памяти/PID и сброшенные capabilities. Это локальная конфигурация: Keycloak работает в start-dev, TLS пока не настроен.

Из корня проекта:

```
if (-not (Test-Path infra/.env)) { Copy-Item infra/.env.example infra/.env }
# Заполните пароли и случайный FSP_WEBHOOK_SECRET длиной минимум 32 символа.
docker compose --env-file infra/.env -f infra/compose.yaml config --quiet
docker compose --env-file infra/.env -f infra/compose.yaml up --build -d
docker compose --env-file infra/.env -f infra/compose.yaml ps
docker compose --env-file infra/.env -f infra/compose.yaml logs --tail 100 migrate api
worker
```

В текущем шаблоне пароль PostgreSQL подставляется в URL подключения. Для этого локального шаблона используйте длинный случайный буквенно-цифровой пароль; пароли с URL-разделителями требуют отдельного URL-кодирования конфигурации. Не публикуйте .env или вывод конфигурации, содержащий секреты.

API: http://localhost:8000/api/v1, Keycloak: http://localhost:8080, Mailpit: http://localhost:8025. Frontend включён в Compose на http://localhost:8081, с VITE_API_MOCK=false и VITE_AUTH_MODE=oidc. Issuer токенов остаётся публичным localhost:8080, а серверный JWKS запрашивается через внутренний хост keycloak. Запуск контейнера Keycloak ещё не означает готовность его HTTP API: в первые секунды проверка JWT может не пройти, пока Keycloak не завершит запуск.

Миграции запускаются отдельным одноразовым сервисом; API/worker ждут его успешного завершения. Prisma db push не используется. /ready проверяет подключение к PostgreSQL и Redis, но не удостоверяет готовность Keycloak. Worker выполняет обслуживание, назначение регулярных заданий, скрытую оценку кода через настроенный Piston и удаление аккаунтов. LLM-проверка ещё не реализована.

Проверка docker compose config --quiet проходит. Сборка и запуск не проверены: доступ к npm блокируется ECONNREFUSED 127.0.0.1:9, текущий docker info сообщает permission denied при подключении к pipe dockerDesktopLinuxEngine. Lockfile backend получен при объединении с main; Dockerfile и CI используют npm ci. Полную воспроизводимость сборки ещё нужно проверить.

После запуска необходимо выполнить Prisma/HTTP-интеграционные сценарии, проверить обработку резюме внутри контейнера, миграции с чистого PostgreSQL, OIDC-вход и работу frontend. Валидная конфигурация Compose этого не доказывает.

После сборки запустите `powershell -ExecutionPolicy Bypass -File ./scripts/check-runtime.ps1`. Скрипт проверяет работающие контейнеры, успешное завершение migrate, /ready и discovery realm scout.

Фронтенд и аккаунты

Для разработки frontend можно запускать отдельно вместо контейнера. Сначала остановите сервис `frontend`, чтобы освободить порт 5173:

```
docker compose --env-file infra/.env -f infra/compose.yaml stop frontend
cd frontend
npm ci
npm run dev:real
```

Откройте http://localhost:5173. Команда dev:real работает на Windows и включает реальный API и OIDC. Регистрация создаёт кандидата; письмо подтверждения доступно в Mailpit на http://localhost:8025. Учётки из моков автоматически в Keycloak не создаются. Администратор Keycloak — admin, пароль находится в локальном infra/.env (KEYCLOAK_ADMIN_PASSWORD).

Для работодателя создайте пользователя в realm scout, подтвердите его email и назначьте realm role employer через административную консоль Keycloak. Свяжите его UUID с компанией операторской командой `backend/scripts/provision-employer.ts` (параметры --subject, --email, --company; DATABASE_URL и OIDC_ISSUER нужны в окружении). Скрипт запускается через tsx после установки backend-зависимостей и prisma:generate. Роль employer сама по себе компанию не создаёт; её отсутствие даёт 403 на корпоративных методах.

Запуск интерфейса пока не доказывает прохождение тестирования: требуется расширение банка, настройка ASSESSMENT_GRADE_POLICY и Piston; первые нормативные профили требуют отдельной проверки.

Публичный стенд с HTTPS

Конфигурация подготовлена для Linux VPS с Docker Compose. Нужны два DNS-имени, которые указывают на VPS: приложение и авторизация, например `scout.example.org` и `auth.example.org`. Для временного стенда можно использовать два имени вида `scout.<IP>.sslip.io` и `auth.<IP>.sslip.io`. Порты 80/TCP, 443/TCP должны быть доступны; сертификаты получает Caddy.

1. Создайте `infra/.env` из примера и замените все три секретных значения. Пароль PostgreSQL должен быть длинным случайным буквенно-цифровым значением: в этом шаблоне он используется внутри URL без дополнительного кодирования.
2. Добавьте в `infra/.env`:

```
dotenv APP_DOMAIN=scout.example.org AUTH_DOMAIN=auth.example.org
```

1. Подготовьте импорт realm для публичного адреса:

```
sh node scripts/prepare-public.mjs https://scout.example.org
```

1. Проверьте конфигурацию и запустите:

```
sh docker compose --env-file infra/.env -f infra/compose.yaml -f infra/compose.public.yaml config --quiet docker compose --env-file infra/.env -f infra/compose.yaml -f infra/compose.public.yaml up --build -d docker compose --env-file infra/.env -f infra/compose.yaml -f infra/compose.public.yaml ps
```

Миграции выполняются перед API. Frontend собирается с реальным API и публичным OIDC issuer. Keycloak работает в `start` с TLS на reverse proxy; административный путь закрыт на публичном Caddy. Для административного доступа используйте SSH туннель к loopback-порту 8080 на VPS. PostgreSQL, Redis, Mailpit и API также слушают только loopback; наружу открыт Caddy.

Realm импортируется при первом создании. Импорт не обновляет существующий realm: для прежней установки вручную измените redirect URI, web origins и logout URI клиента `scout-frontend`, прежде чем переходить на публичный адрес. Не удаляйте рабочие тома ради повторного импорта.

Приёмка

- Откройте `https://APP_DOMAIN/api/v1/ready`: ожидается успешный ответ.
- Откройте `https://AUTH_DOMAIN/realms/scout/.well-known/openid-configuration`: issuer должен точно совпадать с публичным URL realm.
- Пройдите вход кандидата и работодателя, проверьте callback и выход.
- Создайте работодателя и свяжите его с компанией по инструкции локального запуска.
- Настройте SMTP для реальной регистрации. Mailpit оставлен для демонстрационных учётных записей и не доставляет письма реальным адресатам.
- Настройте и проверьте банк, политику подтверждения и Piston перед демонстрацией полноценного теста; HTTPS сам по себе не устраняет ограничения банка.

Быстрый вход из мок-демо не переносится автоматически в Keycloak. Для жюри нужны отдельные подготовленные аккаунты; автоматический вход и их начальные данные в этой итерации не реализованы. Сборка образов, выдача сертификата и вход на VPS ещё не проверены: VPS не предоставлен, локальный Docker daemon недоступен.

Подбор кандидатов

Категория и видимость

Поиск использует подтверждённую категорию теста, а не заявленную специализацию профиля. Нужны действующее согласие на публикацию, подтверждённый грейд и статус поиска работы. Скрытие от компании проверяется и в списках, и при прямом открытии карточки.

Начальная модель

Strength = 0.65 × P' + 0.15 × подтверждённые навыки + 0.10 × задания + 0.10 × полнота + бонус ФСП (0–15).

P' = 50 + (перцентиль – 50) × ρ, где ρ = τ² / (τ² + SE²), τ² = 0.8² / 12 — разброс θ внутри одной категории шириной 0.8. При SE ≈ 0.5 перцентиль внутри категории почти целиком шум, и его вес падает примерно до 0.2. На карточке показывается исходный перцентиль. Почему так, см. validation.md.

Fit = 100 × (0.40 × покрытие навыков + 0.25 × сходство словаря + 0.15 × отрасль + 0.20 × условия).

Score = clamp(0.6 × Fit + 0.4 × Strength – штраф точности, 0, 100).

Офлайн-сходство — Jaccard по идентификаторам навыков, не эмбеддинги. Поле `semantic` сохранено для совместимости API, но evidence явно указывает выбранную метрику. Начальные веса не обучены на экспертной разметке; оценка качества подбора ещё предстоит.

Подтверждённый навык весит в 1.5 раза больше заявленного. Желательные навыки имеют половинный вес. Пропущенные навыки уже уменьшают покрытие; их пояснение не добавляет второй штраф. Публикуемые вклады факторов суммируются до итогового скора с учётом округления и ограничения сверху.

ФСП учитывает только проверенные достижения с корректной прошедшей датой. При отсутствии истории отдельного отрицательного фактора нет.

Версии и shortlist

Каждое уточнение создаёт новую неизменяемую запись SearchVersion. Номер версии назначается под блокировкой строки Search. Shortlist связан с Search, а не SearchVersion. Изменение фильтров не удаляет shortlist. Если кандидат отозвал публикацию, запись сохраняется внутри БД, но перестаёт показываться работодателю.

Выдача для сохранённой версии пересчитывается по актуальным профилям: сохраняются условия поиска, но не замороженный снимок персональных данных.

Ограничения текущей реализации

Ранжирование обрабатывает подходящих по специализации/грейду кандидатов в памяти после предварительной фильтрации PostgreSQL. Сложность линейна по размеру подходящей категории.

Нагрузка и реальные пределы пока не измерены. Для больших категорий необходимы SQL-предфильтрация по навыкам/условиям и последующее ранжирование ограниченного множества.

Контакты раскрываются по отдельной записи Disclosure конкретной компании. Свободные поля опыта очищаются от известных контактов и типовых форматов. Это уменьшает риск утечки, но требует дополнительных интеграционных проверок, включая косвенные признаки личности в свободном тексте.

Валидация теста и подбора

Отчёт собирается одной командой из `backend`:

```
npm run eval   # ~40 с, seed 20261010, результат в backend/eval/validation-report.json
```

Скрипт `backend/eval/validate.ts` вызывает боевой код и ничего из него не копирует: выбор задания `selectFamily`, оценку `scoreCompletion` и `scoreOutcome`, контроль экспозиции `exposure`, банк `LIVE_BANK` с генерацией экземпляров `instantiate`, проверку ответа `gradeAnswer`, подтверждение навыков `confirmedSkills`, перцентиль `empiricalPercentile`, фильтры и скоринг подбора `hardFilters` и `explain`, текстовый ранжировщик `/eval/rank` (`rankExternal`), метрики `rankingMetrics`. Цифры в этом документе взяты из отчёта и вручную не правились. Старая симуляция `eval/simulate.ts` удалена: в ней ответы генерировала та же модель, которой их потом оценивали, а банк был выдуманным.

Методика

Всё синтетическое. Реальных кандидатов с известным «настоящим» уровнем у нас нет, как и у конкурентов. Поэтому отчёт проверяет, как алгоритм ведёт себя на популяции со скрытой истиной. Это не доказательство того, что тест работает на живых людях.

Генератор ответов не совпадает с оценщиком. Оценщик знает только экспертные `a = 1,2` и `b` из банка и считает EAP по 2PL. Ответы генерирует 3PL с другими параметрами семейства: `a_true = a × U(0,7; 1,3)`, `b_true = b + U(−0,4; 0,4)`, угадывание `c = 0,02` (все 160 семейств боевого банка числовые, угадать число трудно). Реальный сдвиг: |Δa|/a в среднем 0,16, |Δb| 0,20. Оценщик об этих сдвигах не знает.

Популяция теста. 2000 кандидатов, $\theta \sim N(0,1)$, поровну по 7 специализациям. Истинный грейд определяется по боевым порогам: ниже −1,2 — «ниже junior» (240 человек), junior 453, middle 642, senior 452, lead 213. Заявленный грейд: 60% указывают истинный, 20% на ступень выше, 20% на ступень ниже. Сессии идут подряд с общим счётчиком экспозиции, как в продакшене: потолок 0,4, окно считается по специализации. Политика теста боевая: 8–12 заданий, SE ≤ 0,4, top-5, обязательное покрытие компетенций, в которых у специализации не меньше трёх семейств. Практический блок с кодом не моделируется, `practiceTotal = 0`, как при выключенной песочнице.

Грейд по $\hat{\theta}$ — это полоса, в которую попала оценка. Пять классов: «ниже junior» и четыре грейда. **Решение теста** — подтверждён ли заявленный грейд (`outcome ≠ failed`, то есть $P(\theta \geq \text{порог}) \geq 0,7$). **Продуктовый сценарий**: кандидат идёт по подсказкам системы. Провалил — пересдаёт ступенью ниже, получил `passed_confident` — пробует ступенью выше. Всего не больше четырёх попыток. Итоговый грейд — последний подтверждённый.

ДИ везде — перцентильный бутстрэп, 1000 повторов, 95%. Для теста ресэмплируются кандидаты, для подбора — потребности.

Тест

Метрика (N = 2000)	Значение	ДИ 95%
Точный грейд по $\hat{\theta}$ (5 классов)	**59,0%**	56,9–61,1
Грейд ±1	98,2%	97,6–98,8
к Коэна, квадратичная	**0,816**	0,801–0,829
Корреляция $\hat{\theta}$ и θ (Пирсон)	**0,872**	0,862–0,881
RMSE $\hat{\theta}$	0,487	0,470–0,503
Средняя длина / средний SE	12 заданий / 0,47	
Ложный отказ: грейд ≥ заявленного, но не подтверждён	**22,9%**	20,9–25,1
Ложное подтверждение: грейд ниже заявленного, но подтверждён	22,2%	18,9–25,9
Точность решения «подтвердить / нет»	77,3%	75,4–79,2
Итоговый грейд в продуктовом сценарии, точно	61,8%	59,7–63,8
Фиксированная форма из 12 заданий того же банка, точно / к / r	53,8% / 0,788 / 0,850	

Порог уверенности `passProbability` = 0,6. Его подобрали на отдельном seed 777 по сетке 0,5–0,7: при 0,7 ложные отказы 32,9% против 16,8% ложных подтверждений, при 0,6 ошибки уравниваются (24,6% и 22,9%), а точность решения растёт с 71,5% до 75,9%. На основном seed результат подтвердился: 22,9% и 22,2%, точность 77,3%. Сами пороги грейдов не настраивались: они задают истинный грейд в симуляции, и их подбор был бы порочным кругом. Таблицы слива ниже посчитаны при пороге 0,7; актуальные значения при 0,6 — в `backend/eval/validation-report.json`.

Что исправлено по итогам валидации

Сессия больше не обрывается на обязательном покрытии. Раньше она требовала все компетенции банка, в том числе те, где одно-два семейства, а потолок экспозиции 0,4 их быстро исчерпывал: 48% сессий заканчивались `coverage_unavailable` (409 на `/next`), точный грейд был 51,6%, ложных отказов 64%. Теперь обязательны только компетенции, где семейств не меньше `ceil(1 / maxExposure) = 3` (`requiredCompetencies` в `live-bank.ts`). Если покрытие всё равно упирается в экспозицию, компетенция снимается с обязательных для этой сессии (`selectWithWaiver`, поле `waivedCompetencies` в политике сессии). Так случилось в 60 сессиях из 2000, и все они дошли до 12 заданий.

Test-retest

Тот же кандидат, тот же заявленный грейд, другой seed сессии, отдельная волна из 2000 сессий.

Метрика	Значение	ДИ 95%
Совпадение грейда по $\hat{\theta}$	51,5%	49,3–53,9
к квадратичная	**0,727**	0,705–0,747
Совпадение решения (подтверждён / нет)	72,4%	70,4–74,4
$r(\hat{\theta}_1, \hat{\theta}_2)$	0,769	0,751–0,787
Общих семейств в двух сессиях, в среднем	5,3 из 12	

Слив банка

600 «слабых» кандидатов (θ ниже порога middle, в среднем –1,10) заявляют middle. Любое подтверждение у них ложное. Утекает k% семейств банка специализации. Сценариев два.

- **Утечка ключей экземпляров.** Злоумышленник собрал по 300 реальных экземпляров каждого утёкшего семейства с ответами (генерируются настоящим `instantiate`). Если формулировка совпала дословно, он берёт ответ из дампа, иначе вписывает самый частый ответ дампа. Ответ проверяет боевой `gradeAnswer`.
- **Утечка метода решения.** Кандидат знает, как решать утёкшие семейства, и решает их верно.

Фиксированный тест — те же 12 заданий с постоянными числами для всех, поэтому для него утечка ключа и утечка метода совпадают. Завышение $\hat{\theta}$ считается относительно того же кандидата без утечки.

Утечка	CAT: ключи экземпляров	CAT: метод решения	Фиксированные 12
нет — ложные подтверждения	11,3%	11,3%	12,8%
25% — завышение $\hat{\theta}$ / ложные подтв.	+0,13 / 18,5%	+0,62 / 50,0%	+0,66 / 53,8%
50%	+0,23 / 23,5%	+1,34 / 84,5%	+1,30 / 97,5%
100%	**+0,64** / 49,3%	+2,95 / 99,8%	**+2,74** / 100%

ДИ для каждой ячейки есть в отчёте. При 100% утечке ключей завышение 0,59–0,69. Выводы:

- Параметризация режет вред от слитых ключей вчетверо: +0,64 против +2,74 у фиксированной формы при полном сливе, +0,23 против +1,30 при сливе половины.
- От утечки метода параметризация не защищает, и не должна: знать метод и значит уметь решать.
- **Слабое место банка.** По дампу из 300 экземпляров ответ на новый экземпляр угадывается в среднем с вероятностью 31% (медиана 12%). У 87 из 160 семейств вероятность выше 10%, у 45 выше 50%. Пять семейств, где она была 100% (`live-test-cartesian`, `live-loop-pairs`, `live-binary-tree-height`, `live-js-event-loop-order`, `live-react-memo-renders`), получили широкие диапазоны параметров (банк `v3`). Ещё не исправлены, например, `live-srcset-choice`, `live-closure-var-let`, `live-cidr-hosts`, `live-touch-target`, `live-decision-table`.

Экспозиция

2000 сессий первой волны, 12 заданий в каждой:

Специализация	Семейств	Макс. доля сессий на семейство	Средняя доля
backend	54	0,392	0,222
frontend	42	0,399	0,286
mobile	38	0,399	0,316
qa	40	0,399	0,300
devops	47	0,399	0,255
data_ml	45	0,400	0,267
analyst	44	0,400	0,273

Потолок 0,4 соблюдается, неиспользованных семейств нет.

Подбор

Данные. Два независимых мира: dev для подбора формулы и holdout для отчёта. В каждом 1750 кандидатов (по 250 на специализацию) и 210 потребностей работодателей. У кандидата скрыты θ, набор навыков, которыми он реально владеет (4–7 из 14 самых частых навыков специализации), и

уровень владения каждым (θ + N(0; 0,6)). Наблюдаемое резюме шумное: 10% реальных навыков не указаны, четверть кандидатов «накручивает» резюме (3–5 лишних навыков, грейд на ступень выше, повторы ключевых слов). Каждый кандидат проходит **боевой тест** по продуктовому сценарию. Ответы зависят от θ и от владения навыками, привязанными к семейству, поэтому тест в этой части многомерный, а оценщик нет. Из теста берутся подтверждённая категория, перцентиль внутри категории (`empiricalPercentile`), SE и подтверждённые навыки. ФСП-достижения и регулярные задания тоже генерируются из θ с шумом.

Золотая релевантность считается только по скрытой истине и не использует наблюдаемые поля формулы: ни зарплату, ни отрасль, ни формат, ни заявленные навыки. Метка 0–3 равна `соответствие грейда × (0,7 × доля must-навыков + 0,3 × доля nice-навыков)`. Навык засчитывается, если им реально владеют на уровне не ниже порога грейда – 0,4. Соответствие грейда в основной разметке: совпал — 1, на ступень выше — 0,85, на две выше — 0,6, на ступень ниже — 0,3. Релевантен тот, у кого метка ≥ 2. Для P@10 и MRR@10 берётся именно этот порог, nDCG@10 считается по градуированной метке. Порог переквалификации — произвольное решение авторов, поэтому приведены ещё две разметки: строгая (выше на ступень 0,7, на две 0) и мягкая (любой грейд не ниже нужного — 1). Честно о порядке работы: первой была строгая разметка. После первого прогона стало видно, что вывод зависит от штрафа за переквалификацию. Тогда основной сделали промежуточную, строгую оставили и добавили мягкую. Формулу подбора меняли уже после этого, глядя только на dev.

Системы: * **наш подбор** — боевые `hardFilters` + `explain`; * **BM25** (k1 = 1,2, b = 0,75, реализован в скрипте) по тексту резюме, в том числе заявленный грейд, на всём пуле специализации; * **BM25 + наши фильтры** — тот же пул, что видит наш подбор, но в порядке BM25. Так видно, что даёт именно формула скоринга; * **/eval/rank** — наш текстовый ранжировщик для внешних резюме; * **случайный порядок**.

Holdout, основная разметка, 210 потребностей:

Система	P@10	nDCG@10	MRR@10
Наш подбор	**0,609** (0,572–0,641)	**0,514** (0,488–0,538)	**0,861** (0,824–0,898)
BM25 + наши фильтры	0,590 (0,554–0,623)	0,503 (0,479–0,528)	0,823 (0,789–0,858)
BM25	0,361 (0,333–0,391)	0,309 (0,284–0,334)	0,558 (0,509–0,606)
/eval/rank (только текст)	0,331 (0,307–0,356)	0,292 (0,268–0,314)	0,543 (0,494–0,599)
Случайный	0,216	0,157	0,390

Парные разности на holdout: * наш подбор – BM25: nDCG +0,205 (0,178–0,235), P@10 +0,248 (0,211–0,284); * наш подбор – BM25 на том же пуле: nDCG +0,012 (–0,001…0,025), P@10 +0,019 (0,006–0,031).

Почти весь выигрыш у BM25 даёт пул, то есть жёсткие фильтры по подтверждённой категории и must-навыкам. Сама формула скоринга обходит BM25 на том же пуле совсем немного.

`/eval/rank` уступает простому BM25. Он разбирает навыки словарём и даёт им 60% веса, а лексике только 25%. На резюме с накруткой навыков такой разбор не помогает.

Абляции (holdout)

Без сигнала	P@10	nDCG@10	Разность с полной моделью: nDCG / P@10
— (полная)	0,609	0,514	
без теста	0,411	0,393	**+0,122** (0,095–0,149) / **+0,198** (0,168–0,229)

Без сигнала	P@10	nDCG@10	Разность с полной моделью: nDCG / P@10
без ФСП	0,611	0,515	–0,001 (–0,004…0,003) / –0,001 (–0,006…0,003)
без регулярных задач	0,611	0,520	**–0,006** (–0,011…–0,001) / –0,002 (–0,009…0,005)

«Без теста» значит, что категория берётся из заявленного в резюме грейда, перцентиль равен 50 для всех, подтверждённых тестом навыков нет, видны все кандидаты. Такого режима в продукте нет: без теста кандидат в поиск не попадает.

- **Тест** — главный сигнал: +0,12 nDCG и +0,20 P@10 к ранжированию по заявленному грейду. По строгой и мягкой разметкам вывод тот же (nDCG 0,454 против 0,392 и 0,568 против 0,386). Подтверждённый грейд всё ещё чаще занижен, чем завышен (holdout: верный у 685, на ступень ниже у 601, на две ниже у 69, выше у 73). Поэтому жёсткие фильтры прячут 79% релевантных кандидатов, и это главный резерв.
- **ФСП** — вклад неотличим от нуля. Достижения коррелируют с θ, но после фильтра по грейду высокий θ чаще означает переквалифицированного кандидата. Бонус ФСП полезен как объяснимый факт в карточке, но ранжирование не улучшает.
- **Регулярные задачи** — вклад по nDCG слегка отрицательный (–0,006), по P@10 нулевой. В симуляции задачи зависят только от θ и активности, а не от навыков потребности.

Изменение формулы (одно)

Цифры этого раздела получены до исправления покрытия: изменение формулы делалось раньше.

Первый прогон показал, что внутри пула, прошедшего фильтры, наша формула упорядочивает кандидатов **хуже** BM25: на holdout nDCG 0,372 против 0,397. Больше всего мешал перцентиль. На dev его корреляция с золотой меткой внутри пула отрицательная (–0,10), а весит он 26 баллов из 100.

Объяснение простое. Внутри одной категории шириной 0,8 истинный разброс θ равен $\tau^2 = 0{,}8^2/12 \approx 0{,}053$, а ошибка теста $SE^2 \approx 0{,}25$. Надёжность внутрикатегорийного перцентиля $\rho = \tau^2/(\tau^2 + SE^2) \approx 0{,}2$, то есть примерно на 80% он шум. Изменение в `strength()` (`src/matching/matching.ts`): перцентиль сжимается к 50 с коэффициентом ρ, который считается по SE самого кандидата. Свободных параметров нет, τ берётся из ширины грейда. На карточке и в объяснении по-прежнему показан исходный перцентиль, в evidence добавлен множитель.

	dev, до → после	holdout, до → после
nDCG@10	0,370 → 0,403	**0,372 → 0,409**
P@10	0,488 → 0,496	0,503 → 0,516
MRR@10	0,742 → 0,801	0,750 → 0,795
nDCG@10, строгая разметка	0,252 → 0,311	0,247 → 0,305
nDCG@10, мягкая разметка	0,502 → 0,498	0,515 → 0,518

Решение принималось по dev, holdout подтвердил результат. По мягкой разметке, где переквалификация не штрафуется, изменение нейтрально. Цифры «до» получены на коде коммита 24c1668. Чтобы их воспроизвести, верните прежний `strength()` и запустите `npm run eval`. Тесты обновлены: добавлена проверка, что при меньшем SE перцентиль весит больше.

Сравнение с конкурентами

У всех ниже синтетика с собственными генераторами, порогами и разметкой. Цифры показывают порядок величин, а не результат на общем наборе данных.

Что	Конкурент	Мы
Точный грейд	Shaurma 76% (2000 канд.)	59,0% (5 классов, полоса 0,8)
к	Shaurma 0,87	0,816
Test-retest к	Shaurma 0,864	0,727
r($\hat{\theta}$, θ)	andercat2 0,921	0,872
Ложные отказы	andercat2 22,5%	22,9%
Слив банка: завышение	Shaurma –0,10 (CAT) против +1,32 (фикс.)	+0,23 при 50% ключей, +0,64 при 100%; фикс. +1,30 / +2,74
P@10 против BM25	Shaurma 0,855 против 0,35	0,609 против 0,361
nDCG@10 против BM25	diktator06 0,591 против 0,282	0,514 против 0,309
Вклад ФСП (абляция)	ctrl-alt-win измеряет	–0,001 nDCG, неотличим от нуля

Где мы честно отстаём: точность грейда и повторяемость. Главная причина — 12 заданий и SE ≈ 0,47. Где мы сопоставимы или сильнее: независимость генератора (истинные параметры отличаются от банковских, утечки моделируются через настоящий генератор экземпляров) и честная абляция ФСП. Отрыв от BM25 по подбору у нас меньше, чем заявляют Shaurma и diktator06. Наша разметка не использует поля, на которых работает формула, и BM25 в ней получает тот же заявленный грейд в тексте.

Ограничения и что не проверено

- В банке ещё 45 семейств, ответ которых по дампу из 300 экземпляров угадывается чаще чем в половине случаев (см. «Слив банка»).
- Нет ни одного реального кандидата. Экспертные `b` банка не откалиброваны, а истинные параметры в симуляции — это экспертные плюс шум, не данные.
- В части «Тест» модель одномерная, как у оценщика. Тест получается проще реальности.
- Практическое задание с кодом и вопрос о подходе не моделируются, хотя в продакшене при включённой песочнице они влияют на итог.
- Нет временных эффектов: окна экспозиции в 90 дней, кулдаунов пересдачи, параллельных сессий.
- Разметку подбора придумали мы. Вывод о вкладе теста и ФСП зависит от того, как штрафовать переквалификацию, поэтому приведены три разметки.
- Поведение накрутчиков упрощено: копирование чужих резюме, подмена личности и списывание по ходу теста не моделируются.
- Зарплата, отрасль и формат в разметку не входят. Их вклад в формулу этот отчёт не оценивает и скорее штрафует как шум.